

Линейные методы классификации

Паточенко Евгений
НИУ ВШЭ

План занятия

- Линейные методы классификации (бинарная)
- Логистическая регрессия


Линейные методы классификации (повтор)

Классификация

Модель машинного обучения, используемая для прогнозирования категориальной (дискретной) целевой переменной на основе одной или нескольких независимых переменных (признаков). Целевая переменная принимает конечное число классов или меток.

Может быть:

- Бинарной (классификация на два класса) $Y = \{0,1\}$
- Многоклассовой (классификация на M непересекающихся классов) $Y = \{1, \dots, M\}$
- Многоклассовой (классификация на M классов, которые могут пересекаться) $Y = \{0,1\}^M$




Линейные методы классификации (повтор)

Классификация

Модель машинного обучения, используемая для прогнозирования категориальной (дискретной) целевой переменной на основе одной или нескольких независимых переменных (признаков). Целевая переменная принимает конечное число классов или меток.

Может быть:

- Бинарной (классификация на два класса) $Y = \{0, 1\}$
- Многоклассовой (классификация на M непересекающихся классов) $Y = \{1, \dots, M\}$
- Многоклассовой (классификация на M классов, которые могут пересекаться) $Y = \{0, 1\}^M$



Бинарная классификация

Модель

$$f(x, \beta) = \text{sign} \left(\sum_{i=1}^n \beta_i x_i \right)$$

Бинарная классификация

Модель

$$f(x, \beta) = \text{sign} \left(\sum_{i=1}^n \beta_i x_i \right)$$

Если $\sum_{i=1}^n \beta_i x_i > 0$, то $\text{sign}(\sum_{i=1}^n \beta_i x_i) = +1$, объект относится к положительному классу

Если $\sum_{i=1}^n \beta_i x_i < 0$, то $\text{sign}(\sum_{i=1}^n \beta_i x_i) = -1$, объект относится к отрицательному классу

Бинарная классификация

Модель

$$f(x, \beta) = \text{sign}\left(\sum_{i=1}^n \beta_i x_i\right)$$

Если $\sum_{i=1}^n \beta_i x_i > 0$, то $\text{sign}(\sum_{i=1}^n \beta_i x_i) = +1$, объект относится к положительному классу

Если $\sum_{i=1}^n \beta_i x_i < 0$, то $\text{sign}(\sum_{i=1}^n \beta_i x_i) = -1$, объект относится к отрицательному классу

$\sum_{i=1}^n \beta_i x_i = 0$ — это уравнение разделяющей границы

Бинарная классификация

Модель

$$f(x, \beta) = \text{sign}\left(\sum_{i=1}^n \beta_i x_i\right)$$

Если $\sum_{i=1}^n \beta_i x_i > 0$, то $\text{sign}(\sum_{i=1}^n \beta_i x_i) = +1$, объект относится к положительному классу

Если $\sum_{i=1}^n \beta_i x_i < 0$, то $\text{sign}(\sum_{i=1}^n \beta_i x_i) = -1$, объект относится к отрицательному классу

$\sum_{i=1}^n \beta_i x_i = 0$ — это уравнение разделяющей границы

В двумерном случае разделяющая граница — это прямая

В многомерном — плоскость

Бинарная классификация

Обучение

При обучении классификатора мы минимизируем долю ошибок:

$$Q(f, X) = \frac{1}{n} \left(\sum_{i=1}^n [f(x_i) \neq y_i] \right) \rightarrow \min,$$

где $[f(x_i) \neq y_i] = 1$, если предсказание на объекте неверное, иначе — 0

Бинарная классификация

Отступ (margin)


Отступ — степень уверенности классификатора в ответе

Обозначим отступ на i -ом объекте:

$$M_i = y_i \cdot (\beta, x_i)$$

Тогда решение задачи оптимизации при обучении классификатора эквивалентно решению задачи


$$Q(f, X) = \frac{1}{n} \left(\sum_{i=1}^n [M_i < 0] \right) \rightarrow \min$$



Бинарная классификация

Отступ

Чем ближе отступ к нулю, тем меньше уверенность алгоритма в ответе




Бинарная классификация

Функция потерь

Функция, которую минимизируем при обучении: $Q(f, X) = \frac{1}{n} (\sum_{i=1}^n [M_i < 0]) \rightarrow \min$

Такая функция потерь называется пороговой и она разрывна, что затрудняет процесс ее минимизации




Бинарная классификация

Функция потерь

Для решения этой проблемы используются непрерывные или гладкие функции — верхнюю оценку пороговой функции. Они дифференцируемы и по значению больше либо равны исходной пороговой $\Rightarrow$ автоматически минимизируют и пороговую.

Конкретную функцию выбирают в зависимости от задачи.



$V(M) = (1 - M)$ — кусочно-линейная

$H(M) = (-M)$ — кусочно-линейная

$L(M) = \log(1 + e^{-M})$ — логистическая

$Q(M) = (1 - M)^2$ — квадратичная

$S(M) = 2 \cdot (1 + e^M)^{-1}$ — сигмоидная

$E(M) = e^{-M}$ — экспоненциальная

Логистическая регрессия

Определение

Логистическая регрессия — это линейный классификатор, который предсказывает вероятности классов, то есть:

$f(x, \beta)$ — это вероятность того, что $y = +1$ на объекте x :

$$f(x, \beta) = P(y = +1|x; \beta)$$

Логистическая регрессия

Определение


Логистическая регрессия — это линейный классификатор, который предсказывает вероятности классов, то есть:

$f(x, \beta)$ — это вероятность того, что $y = +1$ на объекте x :

$$f(x, \beta) = P(y = +1|x; \beta)$$

Представляет собой сигмоиду:

$$f(x, \beta) = \sigma(\beta^T x) = \frac{1}{1 + e^{-\beta^T x}}$$




Напоминание

Сигмоида: $\sigma(z) = \frac{1}{1+e^{-z}}$, $\sigma(z) \in (0; 1)$

Логистическая регрессия

Почему сигмоида?




Напоминание

Сигмоида: $\sigma(z) = \frac{1}{1+e^{-z}}$

Логистическая регрессия

Почему сигмоида?

- Область допустимых значений $\sigma(z)$: $[0,1]$




Напоминание

Сигмоида: $\sigma(z) = \frac{1}{1+e^{-z}}$

Логистическая регрессия

Почему сигмоида?

- Область допустимых значений $\sigma(z)$: $[0,1]$
- Интерпретируемая вероятность
противоположного события $\sigma(-z) = 1 - \sigma(z)$



Напоминание


Сигмоида: $\sigma(z) = \frac{1}{1+e^{-z}}$

Логистическая регрессия

Почему сигмоида?

- Область допустимых значений $\sigma(z)$: $[0,1]$
- Интерпретируемая вероятность
противоположного события $\sigma(-z) = 1 - \sigma(z)$
- Существование обратной функции:

$$z(s) = \ln \frac{s}{1-s}, \text{ где } s \text{ — значение сигмоиды}$$



Напоминание

$$\text{Сигмоида: } \sigma(z) = \frac{1}{1+e^{-z}}$$

Логистическая регрессия


Почему сигмоида?

- Область допустимых значений $\sigma(z)$: $[0,1]$
- Интерпретируемая вероятность
противоположного события $\sigma(-z) = 1 - \sigma(z)$
- Существование обратной функции:

$$z(s) = \ln \frac{s}{1-s}, \text{ где } s \text{ — значение сигмоиды}$$

- Удобно дифференцируема:

$$\sigma'(z) = \sigma(z)(1 - \sigma(z))$$



Напоминание

$$\text{Сигмоида: } \sigma(z) = \frac{1}{1+e^{-z}}$$

Логистическая регрессия

Функция потерь

Квадратичную функцию для логистической регрессии использовать не получится:


- Функция примет вид $Q(f, X) = \frac{1}{n} \sum_{i=1}^n \left(\frac{1}{1+e^{-\beta^T x}} - y \right)^2$, а это не выпуклая функция, то есть можем не попасть в глобальный минимум при оптимизации
- На совсем неправильных предсказаниях (например, вероятность 0% для положительного объекта), штраф будет маленьким: $(1 - 0)^2 = 1$

Логистическая регрессия

Функция потерь

Вместо квадратичной используется логистическая функция (log-loss):

$$\text{logloss} = -\frac{1}{n} \sum_{i=1}^n [y_i \cdot \log f(x_i, \beta) + (1 - y_i) \log(1 - f(x_i, \beta))]$$



Логистическая ошибка
на одном объекте

Логистическая регрессия

Функция потерь

В отличие от квадратичной функции потерь, у логистической:

- если $f(x, \beta) = 1$ и $y = +1$ (алгоритм сделал верное предсказание), штраф $L(f, y) = 0$
- если $f(x, \beta) \rightarrow 0$, при $y = +1$ (т. е. предсказание неверное), штраф $L(f, y) \rightarrow +\infty$

Логистическая регрессия

Константное решение

Пусть:

- a — ответ алгоритма
- n_1 — объектов положительного класса
- n_2 — объектов отрицательного класса
- $n_1 + n_2$ — всего объектов в выборке

Логистическая регрессия

Константное решение

Тогда функция потерь примет вид:

$$\text{logloss} = -\frac{1}{n} \sum_{i=1}^n [y_i \cdot \log a + (1 - y_i) \log(1 - a)]$$

Так как в выборке n_1 положительных и n_2 отрицательных объектов, функцию можно представить как:

$$\text{logloss} = -\frac{n_1}{n} \log a - \frac{n_2}{n} \log(1 - a)$$

Логистическая регрессия

Константное решение

Возьмем производную по a и приравняем к 0:

$$\frac{\partial \log \text{loss}}{\partial a} = -\frac{n_1}{n} \frac{1}{a} + \frac{n_2}{n} \frac{1}{1-a} = 0$$

Выразим a :

$$a = \frac{n_1}{n}$$

Что в точности соответствует вероятности встретить объект положительного класса в выборке

Логистическая регрессия

Оптимизация *logloss*

Хотя *logloss* потенциально неограниченная функция, имеет смысл рассматривать значения лучше константного, поэтому принимается диапазон:

$$\textit{logloss} \in \left[0, -\frac{n_1}{n} \log \frac{n_1}{n} - \frac{n_2}{n} \log \frac{n_2}{n} \right]$$